

Ce sunt regulile de asociere?

Analiza regulilor de asociere (Association Rules Mining) este o tehnică de **descoperire a tiparelor** într-un set mare de date, utilizată pentru a găsi relații semnificative între variabile. Aceasta este folosită frecvent în **analiza tranzacțiilor** (*Market Basket Analysis*) pentru a identifica ce produse sunt cumpărate împreună.

O **regulă de asociere** este o expresie de forma:

$$X \Rightarrow Y$$

unde:

- **X** (antecedent) → Set de itemi care apar împreună în baza de date.
- **Y** (consecința regulii) → Item(i) care sunt adesea asociați cu **X**.

Exemplu: Dacă analizăm tranzacțiile dintr-un supermarket, putem descoperi regula:

$$\{\text{Pâine, Unt}\} \rightarrow \{\text{Lapte}\}$$

care exprimă faptul că *dacă un client cumpără pâine și unt, este foarte probabil să cumpere și lapte.*

Metrici utilizate

Pentru a evalua regulile de asociere, folosim următorii indicatori:

1. Suportul (Support)

Suportul unei mulțimi de itemi reprezintă frecvența cu care mulțimea de itemi apare în tranzacții.

$$\text{Support}(X) = \frac{\text{numărul tranzacțiilor care conțin } X}{\text{numărul total de tranzacții}}$$

Suportul unei reguli de asociere:

$$\text{Support}(X \Rightarrow Y) = \text{Support}(X \cup Y) = \frac{\text{numărul tranzacțiilor care conțin } X \cup Y}{\text{numărul total de tranzacții}}$$

Dacă privim X și Y ca evenimente, atunci suportul regulii $X \Rightarrow Y$ este probabilitatea intersecției celor două evenimente:

$$\text{Support}(X \Rightarrow Y) = P(X \cap Y)$$

Interpretare: Cu cât suportul este mai mare, cu atât regula apare mai frecvent în baza de date.

2. Încrederea (Confidence)

$$Confidence(X \Rightarrow Y) = \frac{Support(X \cup Y)}{Support(X)} = \frac{\text{numărul tranzacțiilor care conțin } X \cup Y}{\text{numărul tranzacțiilor care conțin } X}$$

Exprimă probabilitatea ca **Y** să fie cumpărat atunci când **X** este cumpărat:

$$Confidence(X \Rightarrow Y) = \frac{P(X \cap Y)}{P(X)} = P(Y/X)$$

Interpretare: Dacă încrederea este 80%, înseamnă că **80% dintre clienții care cumpără X cumpără și Y.**

3. Lift

$$Lift(X \Rightarrow Y) = \frac{Support(X \cup Y)}{Support(X) \cdot Support(Y)} = \frac{P(X \cap Y)}{P(X) \cdot P(Y)}$$

Interpretare:

- **Lift > 1** → apariția lui X crește probabilitatea lui Y
- **Lift = 1** → X și Y sunt independente
- **Lift < 1** → cumpărarea lui X **scade** probabilitatea cumpărării lui Y.

Extragerea regulilor de asociere din date

1. Se identifică mulțimile frecvente, adică acele mulțimi al căror suport depășește un prag fixat
2. Se identifică regulile de asociere construite peste elementele mulțimii frecvente, care depășesc un grad fixat de încredere

Algoritmul Apriori - cel mai cunoscut algoritm pentru a descoperi **mulțimi frecvente de itemi**. Acesta utilizează o strategie bazată pe **pruning** (eliminarea combinațiilor improbabile) pentru a face căutarea eficientă, care are la bază *principiul apriori*:

Orice submulțime a unei mulțimi frecvente trebuie să fie și ea frecventă (să aibă suportul mai mare decât pragul).

Tema: Extragerea de reguli de asociere din date tabelare

1. Discretizați attributele numerice; lucrați cu mai multe metode
2. Fixați praguri pentru metricile *suport și încredere*
3. Extrageți regulile de asociere utilizând apriori (opțional și fp-growth); ordonați regulile după metricile discutate și identificați reguli ce pot căpăta o interpretare utilă
4. Analizați
 - a. Cum variază mulțimea de reguli la schimbarea pragurilor de la punctul 2? (2p)
 - b. Care metodă de discretizare a datelor este de preferat pentru setul supus analizei? (2p)
 - c. Extrageți reguli utile și motivați (2p)
 - d. Ce reguli pot fi extrase pentru a construi un clasificator? Comentați asupra calității acestora din punct de vedere al acurateței și acoperirii (3p)
 - e. Realizați grafice care să ofere suport în analiza rezultatelor (1p)